Deep Learning para Clasificar tumores cerebrales

Juan Sebastián Chitiva Guerrero
A01276239@tec.mx
Tecnológico de Monterrey
Querétaro, Querétaro, MX

Abstract

Se utiliza un dataset que contiene resonancias magnéticas cerebrales de usuarios con las siguientes 4 categorías:

- Meningioma
- Tumor Pituitario
- Glioma
- Cerebro sano.

En base a las imágenes se construye una red neuronal que permita clasificar estos grupos de manera adecuada, analizando y aprendiendo características visuales como bordes, texturas y patrones especiales que permitan mejorar su predicción. Se utiliza la métrica *Accuracy* y **F1 Score** para determinar la efectividad del modelo.

1 Introducción

Los tumores cerebrales representan una complicación en la salud del ser humano, en especial por su localización y la variedad de tipos que pueden presentarse. Es por eso que se identifican e interpretan a través de imágenes de resonancia magnética **(MRI)** la cual permite analizar características visuales que asocien y permitan dar un diagnóstico dependiendo de lo encontrado.

En este proyecto se propone desarrollar un modelo de Deep Learning que permita clasificar imágenes de las resonancias magnéticas en cuatro categorías: glioma, meningioma, tumor pituitario y un cerebro sano sin tumor. Para poder realizar esto, se usará una red neuronal convolucional que contenga una arquitectura enfocado en análisis de imagenes, ya que esto permite aprender sus características visuales y reconocimiento de patrones.

2 Comprensión de los datos

2.1 Información Inicial

Se realizará la clasificación con un dataset encontrado en Kaggle, el cual contiene las imágenes de resonancia magnética las cuales están organizadas en cuatro categorías:

- Meningioma
- Pituitario
- Glioma
- Cerebro sano.

Cada imagen constituye una muestra de entrada hacia el modelo, mientras que la categoría de la imágen representa nuestra etiqueta para el modelo. El dataset se ha obtenido de la siguiente liga: **https://www.kaggle.com/datasets/ishans24/brain-tumor-dataset**

2.2 Objetivos Analíticos

Clasificar tumores y poder clasificar su tipo a través de resonancias magnéticas cerebrales, permitiendo mejorar el análisis y procesamiento de este tipo de diagnósticos.

2.3 Definiciones y métricas clave

Definiciones:

- **MRI:** Imagen de Resonancia Magnética

Métricas clave:

Para poder determinar la efectividad de los modelos, se buscará usar las siguientes métricas:

- **Accuracy:** Determina el porcentaje del conjunto que ha sido predecido correctamente.
- **F1 Score:** Este determina la combinación entre precisión y recall de la clase, por lo que permite evaluar las dos en conjunto.

3 Análisis Exploratorio

El dataset contiene 10,560 imágenes, las cuales contienen múltiples dimensiones y formatos de color, los cuales son RGB, RGBA y la escala de grises (L). También se analiza el formato en el que viene contenida la imagen.

Formato de Imagen:

- **jpeg:** 7,490 imagenes.
- **png:** 3,070 imagenes.

Formato de color:

- **RGB:** 4,392 imagenes.
- **L:** 3,099 imagenes.
- **RGBA:** 3,068 imagenes.
- **P:** 1 imagen.

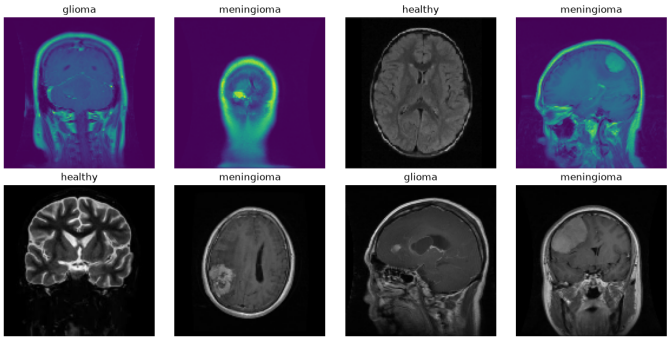


Figure 1: Ejemplos de Categorías

Table 1: Análisis Exploratorio por categoría

Categoría	imagenes revisadas	ancho promedio	alto promedio	modos de color	formatos
Glioma	3,754	509.65	510.10	3	2
Sanos	1,757	306.78	311.68	4	2
Meningioma	2,343	492.21	494.05	3	2
Pituitario	2,706	509.63	509.52	3	2

Se observa que la mayor concentración de las imágenes están en dos formatos, las cuales están distribuidas en todas las categorías. También se puede interpretar que, en promedio, existen variaciones respecto a la dimensionalidad en pixeles de cada una de las categorías.

3.1 Distribución de Dimensionalidad por Clase

Observando la dimensionalidad promedio de cada categoría, se hace un análisis de distribución para observar en donde abunda en su mayoría la dimensionalidad de las imágenes.

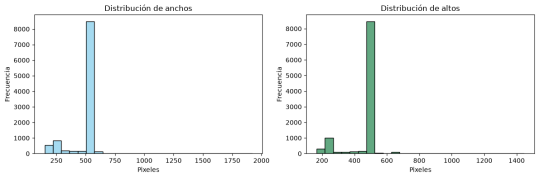


Figure 2: Distribución de imágenes general

Se observa que existen en su mayoría del dataset las imágenes de tamaño 512 x 512 píxeles. Ahora, será importante analizarlos por cada categoría para observar si existe un comportamiento similar entre ellos.

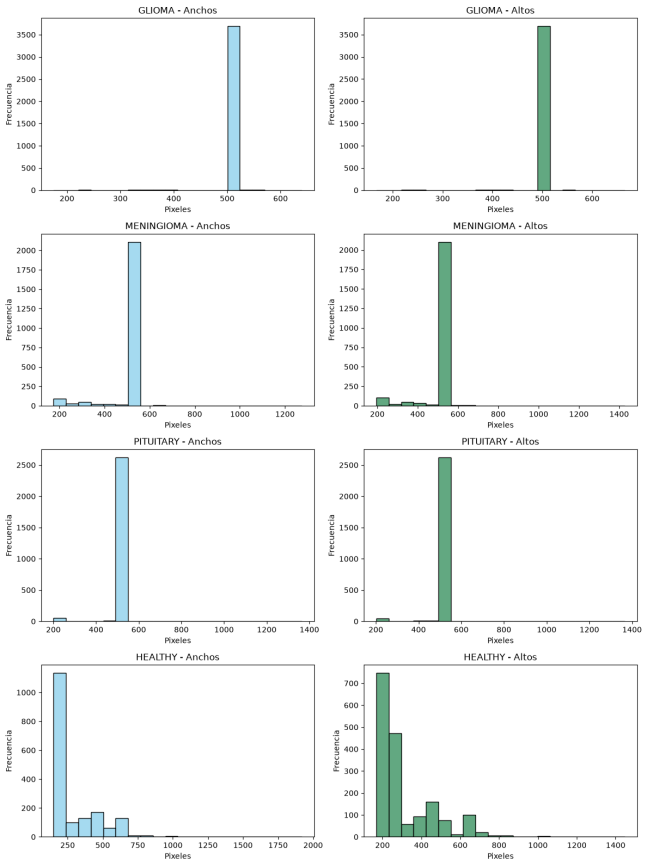


Figure 3: Distribución de imágenes general

Interpretando la distribución por categoría, se observa que las clases de tumores son las que contienen en su mayoría las imágenes de 512 x 512. En el caso de la categoría Sana/No tumor, se observa que las imágenes abundan entre 200 y 500 pixeles, teniendo una mayor variabilidad. Es importante considerar esto a la hora de definir la entrada y procesamiento de dimensionalidad de imágenes.

3.2 Proporción por clase

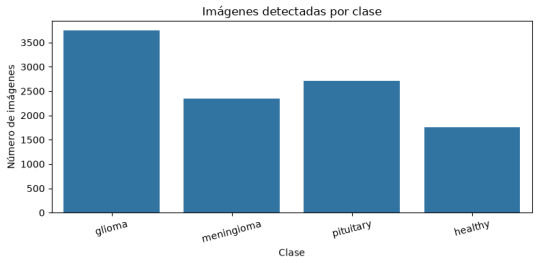


Figure 4: Distribución de imágenes por categoría

Analizando el gráfico, se puede interpretar que la proporción de las imágenes se dividen en el siguiente orden.

(1) Glioma - 35.55%
(2) Pituitario - 25.62%
(3) Glioma - 22.19%
(4) Glioma - 16.64%

4 División de conjunto de datos

Para realizar el entrenamiento y evaluación del modelo, se busca dividir este conjunto de datos en tres subconjuntos.

(1) **Entrenamiento (80%):** Es utilizado para que la red neuronal pueda reconocer y aprender los patrones que existen en las imágenes.
(2) **Validación (5%):** Se utiliza para monitorear el aprendizaje y realizar los ajustes de hiperparámetros para mejorar el modelo.
(3) **Prueba (15%):** Se reserva para evaluar el desempeño final del modelo con imágenes que no participaron en el entrenamiento ni en los ajustes.

Esta división se realizará de manera estratificada, de tal manera que los conjuntos de datos conservan una representación proporcional de las cuatro categorías en cada subconjunto, de tal manera que en cualquier subconjunto que se utilice, exista información para evaluar de todas las categorías mencionadas.

5 Preprocesamiento de Imágenes

La preparación de imágenes se realizan antes de ser introducidas en la red neuronal. Se implementó la función *image dataset from directory* que viene en la librería de Tensorflow/Keras. Esta función permite cargar automáticamente las imágenes desde las carpetas ya divididas a los conjuntos de entrenamiento, validación y prueba.

Como preprocesamiento, se redimensionan todas las imágenes a una resolución de 128 x 128 píxeles y convertidas a formato de color RGB. Esto se ha decidido debido a lo encontrado en la

exploración inicial y a lo que la mayoría de imágenes contiene de formato de color. También se establece un tamaño de lote de 32 imágenes para poder procesar los datos de una manera agrupada en el entrenamiento.

Las etiquetas se han codificado a través de valores enteros, los cuales corresponden a cada categoría a predecir (glioma, meningioma, tumor pituitario y cerebro sano).

Para transformar los colores a un intervalo de [0,1], se ha aplicado una normalización a los valores de píxeles a través de la capa de rescaling $\frac{1}{255}$. Para optimizar la carga de datos en el entrenamiento, se utiliza la función *PREFETCH*.

De esta manera todas las imágenes contienen el mismo formato de entrada para poder facilitar el procesamiento de la red neuronal.

6 Arquitectura inicial

Como una aproximación incial, se diseñó una red neuronal convolucional (CNN) para realizar la clasificación de imágenes en cuatro categorías. El modelo recibe imágenes de entrada con dimensiones de 128x128 píxeles y tres canales de color (RGB).

La arquitectura comienza con una capa de entrada y Data Augmentation, lo cual tiene el objetivo de generar variaciones en las imagenes durante el entrenamiento y así contribuyendo a mejorar la capacidad de generalización del modelo.

En la arquitectura se implementan cuatro capas convolucionales con 32, 64, 128 y 256 filtros, respectivamente. Estas capas ayudan a extraer las características visuales de las imágenes. Después de las primeras tres capas convolucionales se aplican capas de Max Pooling, las cuales reducen que reducen las dimensiones de los mapas de características.

Después, se utiliza una capa de Global Average Pooling, la cual transforma los mapas de características en un vector de 256 elementos. Después se incorpora una capa Dropout para reducir el riesgo de sobreajuste.

La etapa de clasificación está compuesta por una capa densa de 128 neuronas, seguida de otra capa Dropout y una capa de salida de cuatro neuronas, correspondientes a las cuatro categorías que debe reconocer el modelo.

Table 2: Arquitectura de la red neuronal convolucional

Capa	Dimensión de salida	Parámetros
Input Layer	$128 \times 128 \times 3$	0
Data Augmentation	$128 \times 128 \times 3$	0
Conv2D (32 filtros)	$128 \times 128 \times 32$	896
Max Pooling	$64 \times 64 \times 32$	0
Conv2D (64 filtros)	$64 \times 64 \times 64$	18,496
Max Pooling	$32 \times 32 \times 64$	0
Conv2D (128 filtros)	$32 \times 32 \times 128$	73,856
Max Pooling	$16 \times 16 \times 128$	0
Conv2D (256 filtros)	$16 \times 16 \times 256$	295,168
Global Average Pooling	256	0
Dropout	256	0
Dense (128 neuronas)	128	32,896
Dropout	128	0
Dense (4 neuronas)	4	516
Total		**421,828**

En resumen, se crea una red con 421,828 parámetros entrenables, lo cual equivale a 1.61 Mb. Esta arquitectura tiene como objetivo encontrar un equilibrio entre la extracción de características visuales de las imágenes y la capacidad de clasificación con una cantidad relativamente reducida de parámetros. Este modelo funcionará como base inicial de la capacidad del modelo.

Es importante mencionar que la función de pérdida se define con **Sparse Categorical Cross-Entropy**, el cual se utiliza comúnmente para identificar la pérdida en clasificación de multi clase, y como métricas se consideran *accuracy*, el cual permite identificar que porcentaje de la clase ha sido correctamente clasificada y *F1 score*.

6.1 Configuración de Hiperparámetros

Como parámetros del modelo, se estableció un máximo de 20 épocas. Asimismo, se implementaron tres mecanismos de supervisión (*callbacks*) con el propósito de controlar el proceso de aprendizaje, reducir el riesgo de sobreajuste y conservar la mejor versión del modelo.

En primer lugar, se utilizó *EarlyStopping*, configurado para monitorear la pérdida de validación (*val_loss*), con una paciencia de cuatro épocas. Con esto se refiere a que si el entrenamiento no muestra una mejora en dicho periodo, se termina el entrenamiento. También se ha habilitado la restauración de pesos respecto a la época con menor pérdida de validación.

En segundo lugar, se implementó *ReduceLROnPlateau*, con un factor de reducción de 0.5 y una paciencia de dos épocas. Este mecanismo disminuye la tasa de aprendizaje cuando el rendimiento del modelo deja de mejorar, estableciendo como límite mínimo un valor de 1×10^{-6}.

Finalmente, se implementó *ModelCheckpoint*, que permite guardar automáticamente la mejor versión del modelo, tomando como referencia la menor pérdida de validación obtenida durante el entrenamiento.

La configuración se resume en la siguiente tabla:

Table 3: Configuración de hiperparámetros y estrategias de entrenamiento

Parámetro	Valor	Descripción
Épocas máximas	20	Iteraciones completas
EarlyStopping	4	Épocas de espera
Restore best weights	True	Recupera mejores pesos
Factor de reducción	0.5	Reduce el learning rate
Paciencia LR	2	Épocas de espera
Tasa mínima	10^{-6}	Learning rate mínimo
ModelCheckpoint	True	Guarda el mejor modelo

6.2 Evaluación del Modelo

Una vez realizado el entrenamiento del modelo, se observa que aplicó el *early stopping* en la época 8. Este obtuvo un resultado de entrenamiento en Accuracy de 76.86% y Validación de 50.57%. Esto nos da a entender que el modelo si está clasificando correctamente y que si existe una mejora respecto a las primeras épocas.

Aunque si existe una mejora en el entrenamiento, se observa que, para validación en la cuarta época, comienza a disminuir, terminando en 50.57%. Esta diferencia entre ambos desempeños de entrenamiento y validación pueden ser señales de un caso de sobreajuste. Se infiere debido a que el modelo continua mejorando en los datos que se utilizan en el set de entrenamiento, pero no muestra una mejora o un comportamiento similar al utilizar información que no ha visto el modelo en el set de validación.

Igual se puede osbervar que en la séptima época se activó el mecanismo definido *ReduceLROnPlateau*. Este redujo el *learning rate* de 0.0001 a 0.0005 cuando detecta que no existía una mejora en la pérdida de validación.

En la siguiente gráfica se puede visualizar el desempeño de las épocas y su comportamiento de entrenamiento y validación.

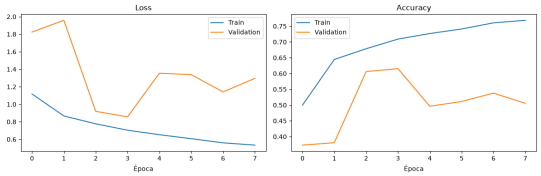


Figure 5: Gráficos de primera iteración de modelo

Para robustecer el diagnóstico del modelo inicial, se ha realizado una predicción respecto al dataset de entrenamiento, obteniendo sus métricas principales y la matriz de confusión, la cual nos permite analizar el comportamiento con un nuevo set de datos.

Este diagnóstico fue realizado con el set de prueba, que contiene 1,584 imágenes de las 4 categorías a predecir.

Durante la evaluación se obtuvo una exactitud (*accuracy*) de 62.63% y una pérdida (*loss*) de 0.8367. Estos resultados indican que el modelo logró clasificar correctamente aproximadamente el 62.63% de las imágenes del conjunto de prueba.

Para analizar el comportamiento del modelo de manera más detallada, se calcularon las métricas de precisión (*precision*), sensibilidad (*recall*) y puntuación F1 (*F1-score*) para cada categoría.

Table 4: Resultados de clasificación del modelo CNN en el conjunto de prueba.

Categoría	Precision	Recall	F1-score	Support
Glioma	0.79	0.58	0.67	563
Meningioma	0.52	0.40	0.45	352
Pituitary	0.75	0.66	0.70	406
Healthy	0.48	0.98	0.64	263
Macro avg	0.63	0.65	0.62	1584
Weighted avg	0.67	0.63	0.62	1584

Los resultados muestran diferencias importantes en el desempeño del clasificador entre las distintas categorías. La clase *pituitary* obtuvo el mayor valor de F1-score, con 0.70, seguida de *glioma*, con 0.67, y *healthy*, con 0.64.

En otro lado, la categoría *meningioma* muestra el menor desempeño, con un F1-score de 0.45. Sus métricas indican que el modelo tiene dificultades tanto para identificar correctamente las imágenes, así como para no asignarle predicciones incorrectas.

También es importante observar el comportamiento de la categoría *healthy*, que obtuvo una sensibilidad de 0.98, pero una precisión de 0.48. Esto significa que el modelo identificó la mayoría de las imágenes saludables, aunque también clasificó incorrectamente imágenes de otras categorías.

Se observa también la matriz de confusión, en la cual se puede analizar las observaciones mencionadas anteriormente.

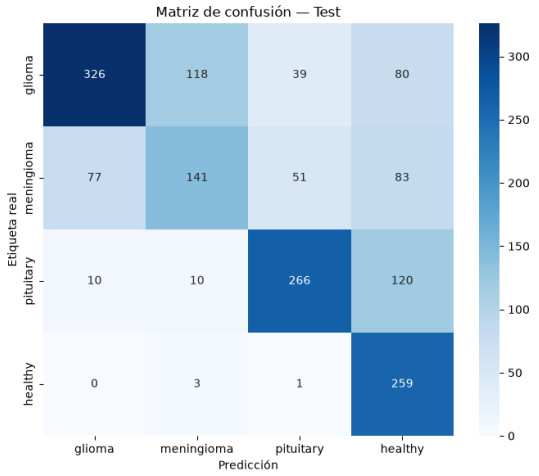


Figure 6: Matriz de Confusión de red neuronal

En general, se observa que el modelo está teniendo un buen comportamiento para ser una aproximación inicial, pero sigue siendo necesario realizar ajustes que permitan mejorar el desempeño de este. De igual manera, se han congelado y guardado los pesos en un archivo con el objetivo de realizar predicciones con lo obtenido.